

APLICAÇÃO DE TÉCNICAS DE APRENDIZAGEM À ANÁLISE DE EXPRESSÃO PROTEICA EM MODELOS MURINOS DE SÍNDROME COM DOWN

Mariana Costa e Nathalia Kuwae

Instituto Superior de Engenharia de Coimbra, Instituto Politécnico de Coimbra

a2022138061isec.pt; a2023154769@isec.pt



Índice

Capa.....	Error! Bookmark not defined.
Índice.....	Error! Bookmark not defined.
Introdução	3
Hipóteses de Investigação	4
Metodologia	4
Pré-Processamento dos Dados	4
Análise Inteligente de Dados.....	5
1. Hipótese 1	5
2. Hipótese 2	7
Conclusão.....	Error! Bookmark not defined.
Bibliografia	8

INTRODUÇÃO

De acordo com o estudo realizado por Higuera C et. al (2015), a Síndrome de Down (SD) é uma anomalia genética associada a deficiência intelectual, que afeta aproximadamente um em cada 1000 nascimentos em todo o mundo. É a mais comum dentre os défices de aprendizagem e memória. Dá-se devido a uma cópia extra do cromossoma 21 humano (Hsa21), e representa uma perturbação genética de complexidade considerável [1].

O Hsa21 codifica mais de 500 genes, e um subconjunto desconhecido contribui para os défices de aprendizagem. A sobre-expressão dos genes (ou seja, quando os mecanismos de controlo falham levando a um aumento anormal da quantidade de mRNA e, consequentemente, a um excesso da proteína ou do RNA funcional produzido) irá perturbar inúmeros processos (muitos dos quais afetam o desenvolvimento e a função cerebral) e vias biológicas diferentes. Devido a esta complexidade, a escolha dos alvos dos fármacos deve levar em consideração perturbações em vias que são críticas para a aprendizagem e memória e, só então, considerar fármacos que corrijam as perturbações observadas [1].

Examinou-se os efeitos da memantina (medicamento utilizado no tratamento da Doença de Alzheimer) na expressão proteica, com e sem aprendizagem no condicionamento de medo contextual (CFC). Analisou-se as respostas proteicas no modelo murino de trissomia parcial da SD, Ts65Dn e obteve-se os seguintes resultados: os ratinhos Ts65Dn não tratados falham na aprendizagem no CFC, mas se forem injetados primeiro com memantina, aprendem com sucesso, ou seja, a aprendizagem é resgatada. A comparação dos perfis proteicos entre os Ts65Dn quando falham no CFC, os Ts65Dn quando a sua aprendizagem é resgatada com memantina e os ratinhos de controlo tratados de forma semelhante revelou alterações estatisticamente significativas nos níveis proteicos associados à aprendizagem normal, falhada e resgatada, alterações nos níveis proteicos causadas pelo tratamento com memantina isoladamente, e diferenças nas respostas entre ratinhos de controlo e Ts65Dn [1].

O *dataset* utilizado, que será o mesmo deste presente estudo, contém níveis de expressão de 77 proteínas/modificações proteicas medidas no córtex cerebral dos ratinhos. O estudo contou com 38 ratinhos de controlo e 34 trissómicos, com um total de 72 ratinhos. A capacidade de aprendizagem dos ratos depende da combinação dos 3 seguintes fatores: tipo de rato, existência de tratamento e realização de experiência de estímulo à aprendizagem (Fig.1).




Figura 1 - **Classes de ratinhos.** (A) Existem oito classes de ratinhos baseadas no genótipo (controle, c, e trissomia, t), no estímulo para aprender (Contexto-Choque, CS, e Choque-Contexto, SC) e no tratamento (salina, s, e memantina, m). O Resultado da Aprendizagem indica a resposta à aprendizagem para cada classe. (B) Número de ratinhos em cada classe.

Por fim, o presente estudo terá como objetivo principal analisar os dados de expressão das 77 proteínas nas diferentes condições experimentais (controlo: c-CS; trissómicos: t-CS-s; tratamento com memantina: t-CS-m) e tentar identificar padrões importantes relacionados à aprendizagem.

HIPÓTESES DE INVESTIGAÇÃO

De modo a identificar padrões que relacionem e identifiquem as 8 classes do estudo com os níveis das 77 proteínas, procedeu-se a escolha de duas Hipóteses de Investigação.

Hipótese 1: “Há diferença significativa nos níveis de expressão proteica entre ratos de controlo e ratos com Síndrome de Down.”

Esta hipótese, assume que a Síndrome de Down provoca alterações moleculares no cérebro, as quais refletem nos níveis de expressão proteica, e desta forma, os ratos de controlo e os ratos com SD não devem apresentar perfis proteicos semelhantes. Isto porque, a trissomia 21 está associada a alterações sinápticas, défices de aprendizagem e alterações na regulação das proteínas neuronais [1], logo é de se esperar que uma condição genética diferente, provoque diferenças detetáveis a nível proteico. Por fim, de um modo geral, visa testar se os níveis de expressão das proteínas separam naturalmente os dois grupos de ratinhos.

Hipótese 2: “Os perfis de expressão proteica permitem distinguir ratos do grupo de controlo tratados com Memantina dos não tratados, independentemente da condição de aprendizagem.”

Por sua vez, esta hipótese, assume que mesmo nos ratos saudáveis (grupo controlo), a memantina é capaz de provocar alterações moleculares estimáveis. Estas alterações são suficientemente fortes e tendem a criar padrões distintos de expressão proteica independente da aprendizagem. A memantina está associada a alterações na plasticidade sináptica, ou seja, mesmo que não se identifique uma doença, pode haver alterações nas vias neuronais e nos níveis proteicos. Assim, é de se esperar que haja diferenças moleculares mesmo nos ratos de controlo.

METODOLOGIA

Pré-Processamento dos Dados

O dataset em questão, como já mencionado anteriormente, contém níveis de expressão de 77 proteínas medidas no córtex cerebral de ratinhos, sendo que 38 fazem parte do grupo de controlo (saudáveis) e 34 fazem parte do grupo com Síndrome de Down.

Antes da aplicação de técnicas de Análise Inteligente de Dados, foi necessário a aplicação de um conjunto de etapas de Pré-Processamento dos dados. Numa fase inicial, foi feita uma inspeção geral do dataset, de modo a obter informações como: quantidade de colunas existentes, tipos de dados e a existência de valores nulos. Optou-se por, ao invés de remover esses valores ausentes/nulos, substituir os valores em falta, pela média da expressão da respetiva proteína dentro da mesma classe experimental. Desta forma, é possível preservar a maior quantidade possível de informação biológica relevante.

Após este tratamento dos valores em falta, procedeu-se a codificação das variáveis categóricas, convertendo-as em valores numéricos de modo a ser mais adequado à aplicação de algoritmos de aprendizagem automática.

Por fim, aplicou-se uma normalização do tipo z-score às variáveis dos níveis de expressão proteica. Esta, é uma etapa crucial para a aplicação posterior dos algoritmos como PCA, métodos de clustering e classificadores supervisionados, de modo a garantir que todas as proteínas

contribuam de forma equilibrada para a análise dos dados. O resultado deste Pré-Processamento é um dataset preparado para avaliar as hipóteses de investigação propostas anteriormente.

Análise Inteligente de Dados

1. Hipótese 1

1.1) PCA

O PCA (Análise de Componentes Principais) é um método de aprendizagem não supervisionado, tendo por objetivo a redução da dimensionalidade do dataset e a identificação de padrões nos perfis das expressões proteicas, sem recorrer à informações das classes. Deste modo, esta etapa será útil para mostrar a existência de uma tendência de separação natural entre os ratos dos grupos de controlo e com Síndrome de Down.

Através da análise do gráfico obtido (Fig. 2), é possível observar que há uma ampla sobreposição entre os dois grupos. Os pontos azuis (grupo de controlo) e os pontos laranja (Síndrome de Down) estão fortemente misturados e sobrepostos. Este resultado sugere que as principais fontes de variabilidade nos níveis de expressão proteica não estão diretamente relacionadas com o genótipo (terem ou não Síndrome de Down). Entretanto, a ausência de separação clara não exclui a existência de diferenças subtis entre os grupos, como é possível perceber pelo gráfico. Por menor que seja o número de pontos não sobrepostos, é possível a identificação de alguns deles. Por fim, o PCA sozinho não é capaz de validar esta hipótese, apesar de também não invalidar, uma vez que analisa se um modo mais geral.




Figura 2: Gráfico do PCA da primeira hipótese

1.2) Clustering (K-means)

Adicionalmente, aplicou-se o algoritmo *K-means* com $k=2$, de modo a conseguir avaliar a hipótese 1. Este algoritmo se trata de um método de aprendizagem não supervisionado, recorrendo ao agrupamento (*clusterização*) dos dados. Agrupa um conjunto de n pontos de dados em K grupos (*clusters*), onde K é um número inteiro positivo predefinido (neste caso, usou-se $k=2$).

Analisou-se os resultados obtidos e foi possível perceber que a aplicação do algoritmo resultou numa *accuracy* de aproximadamente 53%, indicando uma correspondência limitada entre os clusters e as classes (controlo e Síndrome de Down). Este valor sugere a ausência de um agrupamento natural fortemente associado ao genótipo, indo de acordo com a elevada sobreposição observada na análise do PCA e reforçando o facto de que as diferenças nos níveis de expressão proteica entre os dois grupos não dominam a variabilidade global do *dataset*.




Figura 3: Gráfico do K-means da primeira hipótese

1.3)Random Forest

O algoritmo Random Forest, é utilizado para resolver problemas de classificação e regressão. É um algoritmo de aprendizagem supervisionada e um exemplo de método *Ensemble*. Este constrói uma “floresta” composta por um considerável número de Árvores de Decisão individuais, treinadas de forma independente.

Os resultados obtidos indicaram um desempenho bastante elevado na distinção entre os ratinhos do grupo de controlo e os ratinhos com síndrome de Down, com um *accuracy* de aproximadamente 99,38% no conjunto de teste, indicando que as amostras foram corretamente classificadas.

A avaliação das métricas por cada classe demonstrou um equilíbrio consistente no desempenho. Para o grupo de controlo, o algoritmo apresentou uma precisão de 99% e um recall de 100%, indicando que todas as amostras deste grupo foram identificadas corretamente, ou seja, aconteceram muito poucos falsos positivos. Relativamente ao grupo de ratinhos com síndrome de Down, a precisão foi de 100% e um recall de 99%, o que indica que todas as previsões positivas correspondem a ratinhos com a doença. Os valores elevados de F1-score para ambos os grupos confirmam a estabilidade do algoritmo.

Accuracy: 0.9938271604938271					
	precision	recall	f1-score	support	
0	0.99	1.00	0.99	171	
1	1.00	0.99	0.99	153	
accuracy			0.99	324	
macro avg	0.99	0.99	0.99	324	
weighted avg	0.99	0.99	0.99	324	

Figura 4: Parâmetros obtidos do algoritmo Random Forest da primeira hipótese

Por fim, o classificador *Random Forest* apresentou um desempenho consideravelmente elevado. Isto indica que os níveis de expressão proteica permitem a distinção quase absoluta dos ratos de controlo com os ratos com Síndrome de Down. No entanto, é de se ressaltar que o dataset contém inúmeras medições por ratinhos, podendo haver dependências entre as amostras do conjunto de treino e teste.

Concluindo, de um modo geral, o PCA e o *K-means* abrangem os dados de uma forma mais global, não encontrando separação clara entre os grupos. Já o *Random Forest* explora relações complexas e supervisionadas, captando diferenças subtis, porém consistentes. Assim, esta análise inteligente dos dados demonstra que embora a diferença entre os grupos seja considerável, foi possível identificar padrões proteicos que estão ligados ao genótipo e poderiam ser identificados através de métodos de análise específicos.

2. Hipótese 2

2.1) PCA

Neste caso, a Análise de Componentes Principais (PCA) foi aplicada apenas nos ratinhos do grupo de controlo, com o intuito de avaliar o impacto do tratamento com Memantina nos níveis de expressão proteica.

Ao analisar os resultados obtidos, chegou-se a conclusão de que os pontos azuis (grupo sem tratamento - controlo) e os pontos laranja (grupo com tratamento) estão fortemente sobrepostos na região central do gráfico. Deste modo, não foi possível observar uma separação clara entre os ratinhos tratados e os não tratados no estudo definido por estas componentes, sugerindo que o tratamento não é a principal fonte de variabilidade global dos níveis de expressão proteica.




Figura 5: Gráfico do PCA da segunda hipótese

2.2) Clustering (K-means)

O algoritmo K-means, nesta segunda hipótese, foi aplicado aos dados correspondentes aos ratinhos do grupo de controlo, com um $k=2$. Esta aplicação teve como objetivo avaliar se os níveis de expressão das proteínas se organizam naturalmente em grupos associados à presença ou não de tratamento com Memantina.

Ao analisar o resultado obtido (Fig. 4), é possível concluir que, com uma accuracy próxima de 0.5/0.6, não há evidência de clusters naturais associados à presença de Memantina. Este resultado revelou a formação de dois clusters com separação parcial. Indo de acordo com a ausência de separação clara identificada na análise de PCA.




Figura 6: Gráfico do K-means da segunda hipótese

2.3)Random Forest

A aplicação do Random Forest aos dados dos ratinhos do grupo controlo revelou uma capacidade de discriminação consideravelmente elevada entre os ratinhos tratados com Memantina e os não tratados, com uma *accuracy* de aproximadamente 99.3%.

O modelo apresentou ainda valores elevados e equilibrados de precision, recall e F1-score para as duas classes, determinando um desempenho consistente. Estes resultados obtidos opõem-se com a ausência de separação clara observada nas análises não supervisionadas (PCA e K-means). Este fator sugere que o efeito do tratamento se manifesta por padrões complexos e não lineares nos níveis de expressão proteica.

Accuracy Random Forest (Hipótese 2): 0.993006993006993

Relatório de classificação:

	precision	recall	f1-score	support
0	1.00	0.99	0.99	68
1	0.99	1.00	0.99	75
accuracy			0.99	143
macro avg	0.99	0.99	0.99	143
weighted avg	0.99	0.99	0.99	143

Figura 7: Parâmetros obtidos do algoritmo Random Forest da segunda hipótese

CONCLUSÃO

De uma forma geral, é possível analisar que tanto o genótipo (ter ou não Síndrome de Down) quanto o tratamento (com ou sem Memantina) conseguiram diferenciar bem os grupos quando analisados com métodos supervisionados (*Random Forest*), mesmo que em métodos não supervisionados essa separação não fosse claramente explícita. O genótipo causa uma variação estrutural forte e consistente, enquanto o efeito do tratamento com Memantina é mais sutil e distribuído, sendo possível perceber apenas por modelos que conseguem identificar relações não lineares entre variáveis.

BIBLIOGRAFIA

[1] Higuera C, Gardiner KJ, Cios KJ (2015) Self-Organizing Feature Maps Identify Proteins Critical to Learning in a Mouse Model of Down Syndrome. PLoS ONE 10(6): e0129126. doi:10.1371/journal.pone.0129126