

Modelação das Propriedades dos Frutos Secos com Redes Neurais Artificiais

Mariana Costa¹, Nathalia Kuwae^{1,2,*}

¹ Mariana Costa, a2022138061@isec.pt

² Nathalia Kuwae, a2023154769@isec.pt

* Corresponding author

{a2022138061}@isec.pt

{a2023154769}@isec.pt

Abstract

In this study, we addressed the challenge of predicting key quality indicators of dried fruits (almond, hazelnuts and walnuts) based on a combination of physicochemical and categorical variables such as moisture content (**MC**), water activity (**aw**), total color difference (**TCD**), hardness (**H**) and friability (**F**). The motivation for this work stems from the growing need in the food industry to automate quality control processes using data-driven models. To approach this problem, we applied two machine learning algorithms: **MLPRegressor** and **Random Forest**, after a complete preprocessing pipeline involving data cleaning, one-hot encoding for categorical variables and standardization. We trained and evaluated the models on separated datasets for different fruit types, comparing predicted and real values using metrics such as **R²**, **MAPE**, and **MSE**. Our results show that both models performed well, with **Random Forest** slightly outperforming **MLP** in predictive accuracy. Visual comparisons confirmed the consistency between real and predicted outputs. These findings highlight the potential of combining classical machine learning with structured preprocessing for predicting food quality. The approach presented here can be adapted to other food types and extended for real-time quality monitoring systems.

Keywords: MLPRegressor; Random Forest; Preprocessing; Artificial Neural Network

1 Introdução

Os frutos secos são comumente utilizados na culinária, confeitaria e panificação devido aos seus grandes benefícios, como seu sabor agradável e por sua elevada densidade energética e nutricional (Guiné et al., 2014a; Hokmabadi e Sedaghati, 2014). Sendo também fonte de inúmeros nutrientes, incluindo gordura monoinsaturada, ácido α -linolênico, proteína, arginina, fibra, vitamina E, magnésio e cobre, bem como uma notável riqueza de fitoquímicos saudáveis, como: fitoesteróis, flavonoides e proantocianidinas (Guine2015). Recentemente, diversos artigos vêm sendo publicados onde descrevem os benefícios aplicáveis à saúde e características dos frutos secos (Bolling2010). Dedicaremos o presente estudo em análise a três tipos destes frutos, nomeadamente: amêndoas, nozes e avelãs.

As amêndoas pertencem à família das Rosáceas. Originárias da Ásia Central, sua cultura foi difundida na Europa pelos romanos (Guine2014). No que diz respeito à textura, esta pertence ao grupo dos frutos duros. Apresentam um aroma específico, podendo ser consumidas com ou sem pele interna (JanickMoore1996, Guine2014).

35 As nozes (*Juglans regia* L.) são uma excelente fonte de ácidos graxos ômega -3, os quais são
36 especialmente benéficos para saúde do coração e cérebro. Dentre os três frutos em análise, a
37 noz é uma das duas com maior capacidade antioxidante e conteúdo fenólico total, sendo rica no
38 hormônio antioxidante melatonina (Guiné et al., 2015).

39 Por sua vez, as avelãs (*Corylus avellana* L.) é mundialmente conhecida, sendo uma das
40 matérias-primas mais importantes para a indústria de pastelaria e chocolate devido à suas carac-
41 terísticas organolépticas. Contribuindo para a nutrição e saúde humana devido à sua composição
42 rica em proteína, óleo, vitaminas e minerais (Alasalvar et al., 2009; Turan et al., 2015; Yağcı e
43 Göğüş, 2009; Guiné et al., 2015).

44 No presente estudo, iremos analisar, separada e detalhadamente através da metodologia
45 CRISP-DM, um conjunto de dados relacionados às propriedades físico-químicas destes frutos,
46 com intuito de extrair o máximo de informações relevantes e desenvolver um modelo inteligente
47 capaz de prever características essenciais destes produtos. Além disto, vamos analisar como o
48 impacto de diferentes técnicas de armazenamento podem afetar a qualidade dos frutos secos,
49 especialmente, amêndoas, nozes e avelãs.

50 2 Estado da arte

51 Os frutos secos, como mencionado anteriormente, são referência quando se toca a quantidade de
52 benefícios e nutrientes. De acordo com Bolling et al. (2010), estes ainda podem ter um impacto
53 significativo no estado antioxidante e nas vias inflamatórias, fatores que podem estar, em parte,
54 na base dos potenciais benefícios na redução de doenças cardiovasculares, diabetes tipo 2 e alguns
55 tipos de cancro.

56 Porém, assim como todos alimentos, a qualidade dos frutos secos pode ser significativamente
57 afetada devido alguns fatores. Em estudos realizados, com amêndoas, avelãs e nozes, concluiu-
58 se que as propriedades físico-químicas destes podem variar conforme a sua origem geográfica,
59 condições de armazenamento, presença ou ausência de pele e tipo de embalagem utilizada. Sendo
60 mais bem preservadas em temperaturas baixas (Guiné et al., 2015).

61 Em amêndoas da Espanha e Romênia, por exemplo, notou-se uma atividade de água (aw)
62 superior a 0.6, fator que não garantia sua estabilidade, ao contrário das outras amostras com
63 valores de aw inferiores a 0.6 (Guiné et al., 2015). Neste mesmo estudo pode-se concluir ainda
64 que houve um aumento da dureza e friabilidade com diferentes condições de armazenamento.

65 De acordo com Dongare et al. (2012), a rede neuronal de um ser humano faz parte do seu
66 sistema nervoso, o qual é constituído por uma grande rede de neurónios interconectados. Por
67 sua vez, a rede neuronal artificial (RNA) é um sistema computacional que faz analogia com as
68 redes neuronais biológicas/humanas. Esta rede se assemelha a um sistema de processamento de
69 dados e tomada de decisão do cérebro humano, e a sua função é ditada pelas conexões entre os
70 elementos que imitam as células e nervos do cérebro (Çelekli et al., 2012; Khataee e Kasiri, 2010;
71 Guiné et al., 2015). Têm sido amplamente utilizadas na modelagem de processos de engenharia
72 de alimentos (Guiné et al., 2015).

73 Guiné et al. (2015) utilizou destas redes neurais para realizar a análise e o estudo do efeito de
74 diferentes condições de armazenamento em algumas das propriedades físico-químicas de frutos
75 secos (nomeadamente, amêndoa, avelã e nozes) de diferentes regiões geográficas. As propriedades
76 químicas estudadas foram: teor de humidade e atividade de água. Já a nível físico, foram
77 estudadas a cor e a textura (dureza e friabilidade).

3 Materias e Metodologia

3.1 Amostras

Os frutos analisados neste estudo foram: amêndoas, avelãs e nozes, todos sem a casca externa, embora alguns tenham mantido a pele interna.

As amostras de amêndoas foram provenientes de três origens: Espanha (SP), com pele; Portugal (PT), com pele; e Estados Unidos (EUA), com e sem pele.

As avelãs analisadas tinham as seguintes origens: Espanha (SP), com pele; Portugal (PT), com pele; e Turquia, sem pele.

Quanto às nozes, as amostras foram obtidas de Portugal (PT), sem pele; Chile (CH), sem pele; Estados Unidos (EUA), sem pele; e Romênia (RO), também sem pele.

3.2 Descrição da Base de Dados

A base de dados analisada encontra-se organizada num ficheiro Excel que contém duas folhas principais, designadas por **"Dados"** e **"Preprocessed"**. Ambas apresentam informações relativas a amostras de frutos secos, sendo que a primeira corresponde aos dados originais recolhidos, enquanto a segunda reflete uma versão já tratada e preparada para análise estatística ou aplicação de algoritmos de aprendizagem automática.

Na folha **"Dados"**, os registos estão estruturados com base em várias colunas que caracterizam cada amostra. As primeiras colunas incluem o **ID** da amostra e variáveis categóricas sob o cabeçalho geral **"INPUTS"**. Estas incluem: **Fruit** (tipo de fruto seco, como amêndoa, avelã ou noz), **Skin** (presença ou ausência de pele, indicado como "yes" ou "no"), **Origin** (origem geográfica), **Storage** (condições de armazenamento, codificadas de forma abreviada), e **Package** (tipo de embalagem). Seguem-se as colunas relativas aos **"OUTPUTS"**, que são variáveis físico-químicas medidas nas amostras. Estas incluem: **MC** (Moisture Content, ou teor de humidade), **aw** (atividade da água), **TCD** (diferença total de cor), **H** (dureza), e **F** (friabilidade).

A folha **"Dados"** apresenta algumas entradas com dados ausentes, especialmente na variável **MC**, o que poderá indicar falhas na medição ou amostras não processadas.

A folha **"preprocessed"**, por sua vez, representa uma versão tratada dos dados originais. Nesta, os atributos categóricos foram transformados em variáveis numéricas, permitindo a sua utilização em modelos estatísticos e computacionais. Por exemplo, os tipos de frutos foram codificados com números inteiros ("amêndoa" = 1, "avelã" = 2, "nozes" = 3), e o mesmo foi feito para os atributos como **Skin**, **Origin**, **Storage** e **Package**. As variáveis de saída, como **MC**, **aw**, **TCD**, **H** e **F**, mantêm-se em formato contínuo, tal como na folha original. Nos casos em que os dados estão em falta, foram utilizados códigos como "-1" para representar valores ausentes.

Além disso, a folha **"preprocessed"** inclui algumas tabelas extras no final, com contagens de amostras e codificações auxiliares que poderão ser utilizadas para verificação cruzada ou segmentação dos dados durante o processo de análise.

De forma geral, esta base de dados apresenta um conjunto bem estruturado de informações relevantes para a análise da qualidade e conservação de frutos secos. A sua organização em duas versões — original e tratada — permite tanto a exploração descritiva dos dados como a sua utilização em abordagens mais avançadas de análise preditiva ou de classificação. O nível de detalhe e a diversidade de variáveis tornam-na adequada para estudos que envolvam o impacto do tipo de fruto, origem, embalagem e armazenamento nas propriedades físico-químicas das amostras.

122 3.3 Modelação com Redes Neurais


123 No contexto da avaliação dos frutos secos, a compreensão das suas propriedades físico-químicas
124 (outputs) é crucial para otimizar os processos de armazenamento e os tipos de embalagens a
125 utilizar, de modo a garantir a melhor qualidade possível dos alimentos.

126 Este estudo consistiu na modelação dos dados, através de redes neurais artificiais (RNA),
127 implementadas em *Python/Spyder*, e na análise dos mesmos relativamente aos diversos parâmetros
128 de saída, os quais caracterizam a qualidade dos frutos.


129 Além disso, foram aplicadas ferramentas de modelação, recorrendo a algoritmos de *machine*
130 *learning* como *Random Forest* e *MLPRegressor*, que permitiram explorar a forma como os *inputs*
131 influenciam nos *outputs*.

132 4 Resultados

133 O conjunto de gráficos, composto por um gráfico de barras e um gráfico circular, mostram os
134 tipos de frutos secos presentes no estudo: amêndoas (1), avelãs (2) e nozes (3). As amêndoas
135 e as nozes aparecem em quantidades iguais, com 2200 unidades cada, enquanto as avelãs estão
136 em menor número, com 1650 unidades. Esta distribuição revela um equilíbrio entre amêndoas e
137 nozes, com uma ligeira sub-representação das avelãs.



(a) Tipos de frutos no gráfico de barras



(b) Tipos de frutos no gráfico circular

Figure 1: Tipos de frutos secos

138 Em relação à ausência de pele (1) ou à presença de pele (2) nos frutos secos, os dados foram
139 separados por tipo de fruto. Para as amêndoas, a maioria está sem pele, como mostra o gráfico
140 de barras correspondente, indicando que esse tipo de processamento é predominante. No caso
141 das avelãs, a maioria também está sem pele, embora a diferença entre com e sem pele seja menos
142 acentuada do que nas amêndoas. Já nas nozes, todas aparecem com pele, o que indica que elas
143 não passaram por um processo de descasque.




Figure 2: Presença ou ausência de pele nos frutos secos

144 Outro aspeto analisado é o armazenamento dos frutos secos, representado por um gráfico
 145 circular. Observa-se que todas as formas de armazenamento (grupo controlo (N) - sem ar-
 146 mazenamento; a temperatura ambiente (AT); em estufa a duas temperaturas diferentes - 30°C
 147 (S30) e 50°C (S50) - mas sem controlo de humidade relativa; em câmaras com humidade contro-
 148 lada (C30 e C50); sob refrigeração (R); e congeladas (F)) foram utilizadas em proporções muito
 149 semelhantes, cada uma com aproximadamente 825 unidades, exceto o grupo de controle (sem
 150 armazenamento), que apresenta um número bastante inferior (275 unidades). Isso sugere que o
 151 estudo teve um foco experimental em diferentes condições de armazenamento, com um grupo de
 152 controle consideravelmente menor.




Figure 3: Tipo de armazenamento

153 O gráfico circular que representa a origem dos frutos secos revela uma predominância clara
 154 de produtos provenientes de Portugal e Estados Unidos da América, seguida pela Espanha.
 155 A Turquia, o Chile e a Roménia apresentam proporções menores. Esta distribuição mostra
 156 uma forte representação da Península Ibérica na amostra, o que reflete tendências regionais de
 157 produção ou fornecimento dos frutos secos analisados.




Figure 4: Origem dos frutos secos

158 O próximo gráfico circular mostra a distribuição dos tipos de embalagem utilizados. A
 159 maior parte das amostras, representando 36,4%, está **sem embalagem**, enquanto os demais
 160 estão distribuídos igualmente entre dois tipos de plástico: **LDPE** (polietileno de baixa densi-
 161 dade) e **LLDPE** (polietileno linear de baixa densidade), com 31,8% cada. O estudo envolve
 162 uma comparação entre produtos embalados com estes dois materiais plásticos e produtos não
 163 embalados.




Figure 5: Tipo de embalagem

164 O histograma, apresenta a **distribuição da diferença total de cor (TCD)** das amostras.
 165 A distribuição é assimétrica à direita, indicando que a maioria das amostras apresentou baixas
 166 diferenças de cor (valores próximos de zero), enquanto um número menor de amostras apresentou
 167 alterações mais expressivas, com valores de TCD ultrapassando 40. Isso sugere que, na maior
 168 parte dos casos, os produtos mantiveram uma estabilidade visual em termos de cor, embora
 169 existam exceções com mudanças significativas.




Figure 6: Histograma de distribuição da diferença total de cor (TCD)

O seguinte histograma, mostra a **distribuição da atividade de água (aw)**. A maior concentração de amostras está na faixa entre 0,4 e 0,6, com um pico em torno de 0,5. Há poucas amostras com valores extremos de atividade de água, seja abaixo de 0,3 ou acima de 0,7. Isso indica que os produtos avaliados possuem, em sua maioria, níveis intermédios de humidade disponível, o que é importante para a estabilidade microbiológica e conservação dos alimentos ou materiais analisados.




Figure 7: Histograma de distribuição da atividade da água (aw)

A figura 8 exibe a distribuição dos valores de **dureza (H)**. Observa-se que os dados possuem uma mediana próxima de 30 e apresentam uma dispersão significativa, com muitos valores acima da média. O boxplot indica uma assimetria positiva, com diversos *outliers* acima de 80, chegando até cerca de 140. Isso sugere que, embora a maioria dos frutos tenha uma dureza moderada, há uma fração significativa com valores extremamente elevados.




Figure 8: Boxplot da dureza (H) dos frutos

181 O boxplot abaixo, representa a distribuição do **teor de humidade (MC)**. A mediana está
 182 próxima de 3,5, com a maior parte das amostras entre aproximadamente 2 e 5. No entanto,
 183 também se observa uma grande quantidade de *outliers* acima de 8, chegando a cerca de 16.
 184 Isso revela que a maioria dos frutos tem baixa humidade, mas há variações consideráveis, com
 185 algumas amostras apresentando níveis muito altos.




Figure 9: Boxplot do teor de humidade (MC) dos frutos

186 O último boxplot, mostra a distribuição da **friabilidade (F)** dos frutos. A mediana está em
 187 torno de 1,2, com a maioria dos valores variando entre 0,5 e 2. Assim como nos outros gráficos,
 188 há *outliers* para valores mais altos, indicando que alguns frutos são muito mais friáveis do que a
 189 média. A presença de muitos pontos fora dos limites superiores reforça a variabilidade na textura
 190 dos frutos.




Figure 10: Boxplot da friabilidade (F) dos frutos

O objetivo do *heatmap*, figura 11, identificar como a variável **Storage**, é relacionada ao tipo de armazenamento, se correlaciona com os outputs físico-químicos: **MC**, **aw**, **TCD**, **H** e **F**.

As maiores correlações observadas foram entre **Storage** e **aw**, e **Storage** e **F**, ambas positivas e moderadas. Isso indica que, dependendo do tipo de armazenamento, a atividade de água (**aw**) tende a crescer, indicando possível retenção de humidade. Da mesma forma, a friabilidade (**F**) também aumenta com o tipo de armazenamento, o que indica que o armazenamento afeta a resistência dos frutos secos analisados.

Por outro lado, **Storage** apresentou correlação muito fraca com **MC**, o que indica que mesmo com variações na atividade de água, o conteúdo total de humidade permanece relativamente constante durante o armazenamento. Isso sugere que a forma como a humidade está presente é que muda, refletido na atividade de água, e não no conteúdo total de humidade.

Além disso, a correlação entre **Storage** e **TCD** foi quase nula, indicando que **TCD** não está relacionada diretamente com o tipo de armazenamento, sendo mais influenciada por outras variáveis. A correlação entre **Storage** e **H** foi fraca, o que também sugere que essa variável não depende diretamente do armazenamento.

Estes padrões fazem sentido e são coerentes com o comportamento esperado dos frutos secos: a atividade de água e a friabilidade são impactadas pelo armazenamento, enquanto a humidade pode permanecer mais estável, especialmente se o sistema estiver embalado ou controlado.




Figure 11: Heat map com a correlação entre o armazenamento e os outputs

4.1 Pré-processamento dos Dados

Antes de proceder à análise e modelação dos dados dos frutos secos, foi necessário realizar um conjunto de etapas de pré-processamento para garantir a consistência, integridade e qualidade da informação. Estas etapas incluíram a separação do conjunto de dados original e a eliminação de dados inválidos ou ausentes. Este trabalho preparatório é essencial para garantir que os modelos analíticos a desenvolver, mais adiante, operem com dados completos, relevantes e adequadamente formatados.

Para garantir uma análise adequada dos dados dos diferentes tipos de frutos, foi necessário dividir o conjunto de dados original em dois subconjuntos distintos. Esta separação justificase pelo facto de, ao aplicar técnicas como o *One-Hot Encoding*, algumas colunas com dados exclusivamente nulos para determinados frutos serem eliminadas, o que poderia comprometer a integridade e veracidade dos dados.

Primeiramente, criou-se um subconjunto contendo apenas os frutos identificados como tipo 1 e tipo 2 (Amêndoas e Avelãs, respetivamente), através de um filtro na coluna **Fruit**. Em seguida, construiu-se um segundo subconjunto contendo apenas os frutos do tipo 3 (Nozes). Para este último, as colunas **H** e **F** foram eliminadas, pois continham apenas valores nulos, sendo irrelevantes para a análise deste grupo.

Após essa separação, foi feita uma limpeza dos dados para remover registos inválidos. No caso dos frutos 1 e 2, foram preservadas as informações da coluna **Package** (uma vez que, neste caso, os zeros (0) não correspondiam a dados nulos, mas sim a um certo tipo de embalamento), enquanto as restantes colunas foram verificadas para identificar e remover linhas que continham os valores 0 ou -1, considerados inválidos ou representando dados ausentes. O mesmo processo foi repetido para os dados do fruto 3, assegurando que apenas registos válidos e completos fossem mantidos. Com isso, a quantidade dos frutos 1, 2 e 3, após a limpeza, diminuiu drasticamente. Onde a base de dados correspondente aos dois primeiros frutos (Amêndoas e Avelãs) passou a ter 388 amostras, e a base de dados correspondente ao terceiro fruto (Nozes) passou a ter um total de 185 amostras. Isso nos leva a concluir que havia, inicialmente, um número considerável de amostras com dados nulos que foram eliminados por meio deste processo.

Com os dados limpos, procedeu-se à codificação das variáveis categóricas utilizando a técnica de *One-Hot Encoding*. Esta técnica transforma colunas com valores categóricos (como **Fruit**, **Origin**, **Skin**, **Storage** e **Package**) em múltiplas colunas binárias, onde cada coluna representa uma categoria específica, permitindo assim a sua utilização em modelos de *machine learning*. Desta forma, cada linha do dataset passa a ter valor 1 (True) na coluna correspondente à sua categoria, e 0 (False) nas restantes, permitindo ao modelo interpretar essas informações de forma correta, sem atribuir qualquer tipo de hierarquia entre elas. O resultado foram dois novos conjuntos de dados com todas as variáveis categóricas convertidas em formato numérico, adequados para análise estatística e modelação preditiva.

4.2 Divisão dos Dados e Normalização

Após a aplicação do *One-Hot Encoding* aos dados, o passo seguinte consistiu em dividir o conjunto de dados em dados de treino e dados de teste, com o objetivo de preparar o cenário para a construção e avaliação dos modelos preditivos. Para isso, procedeu-se à seleção das variáveis dependentes, **Y** (outputs) e independentes, **X** (inputs) de cada conjunto, seguida de uma normalização dos dados, de forma a garantir que todas as variáveis apresentassem escalas comparáveis. Esta normalização é fundamental, sobretudo para algoritmos sensíveis à escala dos dados, e foi realizada utilizando o normalizador **StandardScaler**, que ajusta os dados para que apresentem média zero e desvio padrão unitário.

255 No caso dos frutos 1 e 2 (Amêndoas e avelãs), definiram-se como variáveis dependentes (Y) as
256 colunas MC, aw, TCD, H e F. As variáveis independentes foram determinadas por exclusão dessas
257 colunas do *DataFrame* original. Em seguida, aplicou-se a transformação de normalização aos
258 *inputs*, criando-se um novo *DataFrame* com as mesmas colunas e índices, mas com os valores
259 escalados. O mesmo processo foi repetido para os *outputs*, normalizando os dados de saída
260 para permitir, mais tarde, a comparação dos valores previstos com os valores reais, através da
261 desnormalização.

262 Posteriormente, foi utilizada a função `train_test_split` para dividir os dados normalizados
263 em conjuntos de treino e teste, sendo 70% dos dados alocados para treino e 30% para teste. Esta
264 divisão foi realizada de forma aleatória (`random_state=42`) para garantir a reprodutibilidade dos
265 resultados. Esta abordagem permite treinar os modelos com uma parte dos dados e, depois,
266 validar a sua capacidade preditiva com dados não vistos anteriormente.

267 Os mesmos passos foram seguidos para as nozes (fruto 3), com a diferença de que, neste caso,
268 as variáveis dependentes consideradas foram apenas MC, aw e TCD, uma vez que as outras duas
269 colunas (H, F), no que diz respeito a este fruto em questão, foram automaticamente eliminadas
270 nos processos anteriores por serem preenchidas apenas por dados nulos. Após a seleção das
271 variáveis dependentes e consequente remoção das mesmas para definir os *inputs*, procedeu-se à
272 normalização dos dados de entrada e de saída. Por fim, os dados foram também divididos em
273 conjuntos de treino e teste, aplicando a mesma proporção e metodologia.

274 Desta forma, obteve-se um conjunto de dados devidamente normalizado e estruturado para
275 cada grupo de frutos, separado em dados de treino e teste, permitindo o desenvolvimento rigoroso
276 de modelos preditivos na fase seguinte da análise.

277 4.3 Treino e Avaliação do Modelo MLPRegressor

278 Após a divisão dos dados em conjuntos de treino e teste e a respetiva normalização, procedeu-se
279 à construção de modelos de previsão com recurso a uma rede neuronal do tipo **MLPRegressor**
280 (Multi-Layer Perceptron), fornecida pela biblioteca `sklearn`. Esta abordagem foi aplicada
281 separadamente para os conjuntos de dados dos **frutos 1 e 2** e do **fruto 3**.

282 Para o treino dos modelos, foi instanciado um objeto **MLPRegressor** com duas camadas
283 ocultas de 100 e 50 neurónios, respetivamente, e um número máximo de iterações definido como
284 1000, garantindo assim uma aprendizagem suficientemente profunda. O modelo foi ajustado
285 (treinado) com os dados de entrada normalizados (`X_train`) e as respetivas saídas normalizadas
286 (`Y_train`).

287 De seguida, o modelo foi utilizado para realizar previsões sobre os conjuntos de treino e teste,
288 gerando os valores previstos normalizados. Uma vez que a interpretação dos resultados exige
289 valores nas escalas originais, todas as previsões e os dados reais foram desnormalizados com o
290 inverso do **StandardScaler** aplicado anteriormente.

291 Por fim, a qualidade da previsão foi avaliada com base em duas métricas principais:

- 292 • **Erro Quadrático Médio (MSE)**: avalia a magnitude do erro entre os valores reais e
293 previstos.
- 294 • **Coefficiente de Determinação (R^2)**: mede o quão bem os valores previstos explicam a
295 variabilidade dos valores reais.
- 296 • **Erro Percentual Absoluto Médio (MAPE)**: mede a precisão de previsões como uma
297 percentagem, indicando o quão distante, em média, os valores previstos estão dos valores
298 reais, em termos relativos.

299 Estas métricas foram calculadas individualmente para cada variável dependente em ambos
 300 os conjuntos (treino e teste), permitindo assim uma avaliação precisa do desempenho do modelo
 301 em diferentes fases do processo de modelação.

Table 1: MSE (Erro Quadrático Médio) para as amêndoas e avelãs com MLPRegressor

Variável	Treino (MSE)	Teste (MSE)
MC	0.0904	0.4136
aw	0.0001	0.0004
TCD	2.7401	15.1658
H	144.3027	349.5506
F	0.1576	0.4206

Table 2: Coeficiente de Determinação (R^2) para as amêndoas e avelãs com MLPRegressor

Variável	Treino (R^2)	Teste (R^2)
MC	0.9847	0.9120
aw	0.9927	0.9681
TCD	0.8860	0.4731
H	0.5639	0.0058
F	0.5770	-0.1227

Table 3: MAPE (Erro percentual absoluto médio) para as amêndoas e avelãs com MLPRegressor

Variável	Treino (MAPE)	Teste (MAPE)
MC	0.0500	0.0972
aw	0.0169	0.0321
TCD	0.3917	0.7572
H	0.8952	1.4062
F	0.4651	0.7514

Table 4: MSE (Erro Quadrático Médio) para as nozes com MLPRegressor

Variável	Treino (MSE)	Teste (MSE)
MC	0.0337	0.0989
aw	0.0000791	0.0001740
TCD	7.7644	26.9072

Table 5: Coeficiente de Determinação (R^2) as nozes com MLPRegressor

Variável	Treino (R^2)	Teste (R^2)
MC	0.9585	0.9173
aw	0.9905	0.9835
TCD	0.6393	-0.3729

Table 6: MAPE (Erro percentual absoluto médio) para as nozes com MLPRegressor

Variável	Treino (MAPE)	Teste (MAPE)
MC	0.0500	0.0972
aw	0.0169	0.0321
TCD	0.3917	0.7572

4.4 Treino e Avaliação do Modelo Random Forest

Para sabermos qual modelo é mais eficaz, utilizamos também o modelo *Random Forest* para realizar a previsão dos dados de saída. Inicialmente, criou-se o modelo com 100 árvores de decisão e uma semente fixa para garantir a reprodutibilidade dos resultados. Em seguida, o modelo foi treinado utilizando os dados normalizados de entrada e os correspondentes valores de saída. Com o modelo treinado, foram feitas previsões tanto para o conjunto de treino quanto para o conjunto de teste. Para facilitar a interpretação e comparação com os valores originais, as previsões foram desnormalizadas, ou seja, convertidas de volta para a escala original. Posteriormente, para avaliar a performance do modelo, calcularam-se as métricas de erro quadrático médio (MSE) e coeficiente de determinação (R^2) para cada variável prevista, tanto no conjunto de treino quanto no conjunto de teste. Essa avaliação foi realizada separadamente para os *datasets* dos frutos 1 e 2 e para o *dataset* do fruto 3, permitindo assim uma análise detalhada da capacidade preditiva do modelo *Random Forest* para diferentes tipos de frutos e variáveis analisadas.

Table 7: MSE (Erro Quadrático Médio) para as amêndoas e avelãs com Random Forest

Variável	Treino (MSE)	Teste (MSE)
MC	0.0795	0.5197
aw	0.0000855	0.0006484
TCD	2.7379	14.8221
H	147.0758	304.7402
F	0.1610	0.3855

Table 8: Coeficiente de Determinação (R^2) para as amêndoas e avelãs com Random Forest

Variável	Treino (R^2)	Teste (R^2)
MC	0.9866	0.8895
aw	0.9938	0.9522
TCD	0.8861	0.4851
H	0.5555	0.1333
F	0.5679	-0.0290

Table 9: MAPE (erro percentual absoluto médio) para as amêndoas e avelãs com Random Forest

Variável	Treino (MAPE)	Teste (MAPE)
MC	0.0405	0.0826
aw	0.0151	0.0348
TCD	0.4164	0.7467
H	0.8737	1.2998
F	0.4710	0.7245

Table 10: MSE (Erro Quadrático Médio) para as nozes com Random Forest

Variável	Treino (MSE)	Teste (MSE)
MC	0.0352	0.0980
aw	0.0000616	0.0002688
TCD	8.1206	24.8669

Table 11: Coeficiente de Determinação (R^2) para as nozes com Random Forest

Variável	Treino (R^2)	Teste (R^2)
MC	0.9567	0.9180
aw	0.9926	0.9745
TCD	0.6228	-0.2688

Table 12: MAPE (Erro percentual absoluto médio) para as nozes com Random Forest

Variável	Treino (MAPE)	Teste (MAPE)
MC	0.0365	0.0516
aw	0.0143	0.0321
TCD	0.4934	0.6311

5 Discussão

5.1 Dados originais vs Dados do Modelo MLPRegressor

Após a aplicação e a construção de modelos de previsão com recurso à rede neuronal *MLPRegressor*, a presente secção irá avaliar o desempenho do modelo *MLPRegressor* na previsão de diversas propriedades, nomeadamente: MC, aw, TCD, H e F nos frutos secos 1, 2 e 3 (Amêndoas, Avelãs e Nozes, respetivamente), com base nos dados do conjunto de teste.

O gráfico “*Comparação entre Real e Previsto - MC (Teste)*” ilustra o desenvolvimento do modelo desenvolvido na previsão do teor de humidade (MC) dos frutos. A linha azul com os marcadores redondos ‘o’ corresponde aos valores reais de MC (*Real MC*), enquanto que a linha alaranjada com os marcadores ‘x’ representa os valores de MC previstos pelo modelo utilizado (*Previsto MC*). Numa análise geral, o modelo parece conseguir acompanhar os dados originais, com previsões próximas das variações/flutuações dos valores reais, onde os picos e vales foram replicados de maneira precisa. Ou seja, isso sugere que o modelo *MLPRegressor* conseguiu aprender os padrões relevantes a partir dos dados fornecidos. Para grande parte da amostra, os valores previstos se aproximam bastante dos reais.

Similarmente ao MC, o gráfico “*Comparação entre Real e Previsto - aw (Teste)*” revela uma boa concordância com os valores reais. O modelo demonstra constância em seguir a variação da atividade da água ao longo das amostras do conjunto de teste. A proximidade entre a linha dos valores reais (azul) com a linha dos valores previstos (laranja) é evidente na grande maioria dos pontos, reforçando, assim, a eficiência do modelo na aprendizagem e previsão deste parâmetro.

Por sua vez, na previsão do TCD, observa-se que o modelo *MLPRegressor*, embora consiga captar a direção geral das variações, apresenta limitações na previsão, particularmente em pontos de valores extremos (picos). Em vários momentos, o modelo subestima ou superestima a magnitude dos picos, não tendo sucesso, portanto, em replicar de forma fidedigna as variações reais. Em zonas de menor variabilidade, por outro lado, a proximidade entre os valores previstos e reais é mais notória e satisfatória.


A variável H apresenta uma elevada variabilidade nos dados reais do conjunto de teste. O modelo *MLPRegressor* tenta acompanhar essa variação, e consegue, de certa maneira, seguir a tendência geral dos valores. No entanto, a amplitude das discrepâncias entre os valores reais e previstos é mais notória em comparação com o MC e a aw. Há um número considerável de amostras onde a previsão se afasta dos valores reais, indicando que a capacidade preditiva do modelo é menos eficiente relativamente aos valores da dureza (H).

O desempenho do modelo na previsão da propriedade F exhibe um comportamento misto. Embora em algumas amostras a previsão seja precisa, em outras, a diferença entre o valor real e previsto é considerável. Tal como a variável anterior (H), a natureza dos dados da friabilidade (F) impõe maiores desafios ao modelo. Deste modo, ele não tem grande sucesso ao aprender os dados fornecidos e prevê-los.


Relativamente ao *dataset* do fruto 3, foram analisados apenas os três primeiros parâmetros, nomeadamente: MC, aw e TCD. De um modo geral, os gráficos da comparação entre dados reais e previstos de MC e aw se assemelham aos dos frutos 1 e 2. Observa-se que, para as nozes (fruto 3), a capacidade de previsão do MC se mantém consistente com a que foi observada para os outros dois frutos, com a linha de previsão perto dos valores reais, até mesmo nos pontos de maior variação (picos e vales). De igual modo, para a atividade da água, o modelo se comporta de forma precisa, com a linha prevista a espelhar bem a linha real, demonstrando uma boa generalização do modelo para este fruto também. Por outro lado, na previsão do TCD, observa-se que o modelo *MLPRegressor* apresenta limitações, como denotado na análise dos dois primeiros frutos. A mesma tendência do TCD nos frutos 1 e 2 é igualmente visível no fruto 3. O modelo consegue

acompanhar o perfil geral de TCD, mas a previsão nos picos de maior magnitude é visivelmente inferior.


Em suma, os resultados demonstraram que o modelo *MLPRegressor* apresenta uma performance mais fiel e consistente na previsão do teor de humidade (MC) e da atividade da água (aw) para todas as três variedades de frutos secos, indicando assim a sua facilidade em analisar e prever esses dados. A avaliação revelou desafios na previsão das propriedades TCD, H e F, que, apesar de ter alguma capacidade de seguir a tendência geral, a previsão é menos precisa.




(a) Comparação entre o Real e o Previsto - MC (Teste)




(b) Comparação entre o Real e o Previsto - aw (Teste)



(c) Comparação entre o Real e o Previsto - TCD (Teste)




(d) Comparação entre o Real e o Previsto - H (Teste)




(e) Comparação entre o Real e o Previsto - F (Teste)


Figure 12: Gráficos dos Dados originais vs Dados do Modelo *MLPRegressor*, para as amêndoas e avelãs



(a) Comparação entre o Real e o Previsto - MC (Teste)



(b) Comparação entre o Real e o Previsto - aw (Teste)



(c) Comparação entre o Real e o Previsto - TCD (Teste)

Figure 13: Gráficos dos Dados originais vs Dados do Modelo MLPRegressor, para as nozes

5.2 Comparação Quantitativa entre MLPRegressor e Random Forest

Para uma avaliação quantitativa do desempenho na previsão das propriedades dos frutos (Amêndoas, Avelãs e Nozes), foi inicialmente utilizado o modelo *MLPRegressor*. No entanto, com o objetivo de enriquecer a análise e verificar a robustez dos resultados, recorreu-se também ao modelo *Random Forest*. A comparação entre ambos os modelos foi feita com base em métricas como o *Mean Squared Error* (MSE) e o Coeficiente de Determinação (R^2), aplicadas ao conjunto de dados de teste.

5.2.1 Mean Squared Error (MSE)

O MSE calcula a média dos quadrados dos erros. Valores menores indicam maior precisão.

MC (Teor de Humidade):

- MLPRegressor (Frutos 1 e 2): 0.4136
- Random Forest (Frutos 1 e 2): 0.5197
- MLPRegressor (Fruto 3): 0.0988
- Random Forest (Fruto 3): 0.0980

383 Para o MC, ambos os modelos demonstram excelente desempenho nas nozes, com MSEs
384 relativamente baixos e semelhantes. Para os frutos 1 e 2, o MLPRegressor apresenta desempenho
385 superior ao Random Forest.

386 **aw (Atividade da Água):**

- 387 • MLPRegressor (Frutos 1 e 2): 0.00043
- 388 • Random Forest (Frutos 1 e 2): 0.00064
- 389 • MLPRegressor (Fruto 3): 0.00017
- 390 • Random Forest (Fruto 3): 0.00026

391 A previsão da atividade da água é um ponto forte para ambos os modelos, especialmente
392 para as nozes, onde os MSEs são extremamente baixos. O MLPRegressor mantém uma ligeira
393 vantagem, apresentando valores ainda menores.

394 **TCD (Diferença Total de Cor):**

- 395 • MLPRegressor (Frutos 1 e 2): 15.165
- 396 • Random Forest (Frutos 1 e 2): 14.822
- 397 • MLPRegressor (Fruto 3): 26.907
- 398 • Random Forest (Fruto 3): 24.866

399 Para a variável TCD, o modelo Random Forest apresenta MSEs ligeiramente inferiores em
400 comparação ao MLPRegressor para todos os frutos. No entanto, os valores de MSE são sig-
401 nificativamente maiores, especialmente para as nozes, indicando maior complexidade e menor
402 capacidade preditiva dos modelos para essa variável.

403 **H (Dureza):**

- 404 • MLPRegressor (Frutos 1 e 2): 349.550
- 405 • Random Forest (Frutos 1 e 2): 304.740

406 Ambos os modelos apresentam valores elevados, mas o Random Forest obteve um MSE infe-
407 rior, sendo melhor na previsão da dureza.

408 **F (Friabilidade):**

- 409 • MLPRegressor (Frutos 1 e 2): 0.4206
- 410 • Random Forest (Frutos 1 e 2): 0.3854

411 Para a friabilidade, o Random Forest também apresenta um MSE inferior ao do MLPRegres-
412 sor.

413 **5.2.2 Coeficiente de Determinação (R^2)**

414 O R^2 indica a proporção da variância explicada pelo modelo. Valores mais próximos de 1 indicam
415 melhor ajuste.

416 **MC (Teor de Humidade):**

- 417 • MLPRegressor (Frutos 1 e 2): 0.9120
- 418 • Random Forest (Frutos 1 e 2): 0.8894
- 419 • MLPRegressor (Fruto 3): 0.9173
- 420 • Random Forest (Fruto 3): 0.9180

421 Ambos os modelos apresentam excelente R^2 para MC nos três frutos. O MLPRegressor tem
422 ligeira vantagem para os frutos 1 e 2, enquanto o Random Forest é superior para o fruto 3.

423 **aw (Atividade da Água):**

- 424 • MLPRegressor (Frutos 1 e 2): 0.9680
- 425 • Random Forest (Frutos 1 e 2): 0.9521
- 426 • MLPRegressor (Fruto 3): 0.9835
- 427 • Random Forest (Fruto 3): 0.9745

428 Para aw, ambos os modelos apresentam valores elevados de R^2 em todos os frutos, indicando
429 capacidade preditiva quase perfeita, com vantagem para o MLPRegressor.

430 **TCD (Diferença Total de Cor):**

- 431 • MLPRegressor (Frutos 1 e 2): 0.4731
- 432 • Random Forest (Frutos 1 e 2): 0.4850
- 433 • MLPRegressor (Fruto 3): -0.3729
- 434 • Random Forest (Fruto 3): -0.2688

435 Para TCD, os modelos apresentam R^2 razoáveis (próximos de 0.5) nos frutos 1 e 2, com
436 o Random Forest ligeiramente melhor. Para o fruto 3, ambos apresentam valores negativos,
437 indicando dificuldade significativa de predição, com Random Forest tendo desempenho um pouco
438 melhor.

439 **H (Dureza):**

- 440 • MLPRegressor (Frutos 1 e 2): 0.0058
- 441 • Random Forest (Frutos 1 e 2): 0.1332

442 Ambos os modelos apresentam desempenho fraco para dureza, porém o Random Forest tem
443 R^2 superior, ainda que longe de um ajuste satisfatório.

444 **F (Friabilidade):**

- 445 • MLPRegressor (Frutos 1 e 2): -0.1227
- 446 • Random Forest (Frutos 1 e 2): -0.0290

447 Ambos os modelos apresentam valores negativos de R^2 para friabilidade, indicando incapacidade
448 preditiva para essa variável.

5.2.3 Considerações Finais

De modo geral, para as variáveis MC e aw, o *MLPRegressor* demonstra resultados melhores e mais consistentes para todos os frutos, com MSEs menores e R^2 mais próximos de 1, tornando-o mais confiável para prever teor de humidade e atividade da água.

Para TCD, ambos os modelos enfrentam dificuldades consideráveis, especialmente para nozes, onde os valores de R^2 são negativos. O Random Forest apresenta desempenho ligeiramente melhor.

Para dureza (H) e friabilidade (F), nenhum modelo mostrou capacidade preditiva satisfatória para amêndoas e avelãs, com R^2 muito baixos ou negativos.

Considerando a maior relevância das variáveis MC e aw na avaliação dos frutos secos, o *MLPRegressor* é globalmente o modelo recomendado devido à sua capacidade excepcional nestas propriedades. Já para as demais variáveis, ambos os modelos apresentaram limitações, indicando que esses dados são mais complexos e não facilmente modelados pelas redes neurais ou florestas aleatórias utilizadas.

6 Conclusão

O presente estudo teve como objetivo principal desenvolver modelos preditivos capazes de estimar propriedades físico-químicas de frutos secos — nomeadamente amêndoas, avelãs e nozes — com base em variáveis de entrada relacionadas ao tipo de fruto, origem, embalagem e condições de armazenamento. Para isso, foram aplicadas técnicas de aprendizagem automática utilizando os algoritmos *MLPRegressor* e *Random Forest*, após um rigoroso processo de pré-processamento e normalização dos dados.

Os resultados demonstraram que ambos os modelos apresentaram bom desempenho na previsão de duas variáveis fundamentais para a qualidade dos frutos secos: o teor de humidade (MC) e a atividade da água (aw). Nestes casos, o *MLPRegressor* destacou-se por oferecer maior precisão e melhor coeficiente de determinação (R^2), tornando-se uma opção mais confiável para sistemas de previsão automatizados voltados à monitorização da qualidade.

Por outro lado, para variáveis mais complexas como a diferença total de cor (TCD), dureza (H) e friabilidade (F), ambos os modelos enfrentaram limitações, com desempenhos reduzidos, em especial nas amostras de nozes. Esses resultados indicam que tais propriedades podem depender de fatores ainda não representados nos dados ou exigir abordagens mais sofisticadas de modelação.

De forma geral, o estudo reforça a aplicabilidade de métodos de *machine learning* na área alimentar, oferecendo suporte à tomada de decisão e controle de qualidade em produtos de alto valor nutricional. O modelo desenvolvido pode ser adaptado a outras categorias de alimentos e ampliado para integração com sistemas de monitorização em tempo real, representando uma ferramenta promissora para a indústria agroalimentar.

References

- Guiné, R. P. F., Almeida, C. F. F., & Correia, P. M. R. (2014, October). *Efeito da embalagem nas propriedades físico-químicas de amêndoas durante o armazenamento*. Paper presented at a conference.
- Dongare, A. D., Kharde, R. R., & Kachare, A. D. (2012). Introduction to Artificial Neural Network. *International Journal of Engineering and Innovative Technology (IJEIT)*, 2(1), 1–5.

- 490 Guiné, R. P. F., Almeida, C. F. F., Correia, P. M. R., & Mendes, M. (2015). Modelling the
491 Influence of Origin, Packing and Storage on Water Activity, Colour and Texture of Almonds,
492 Hazelnuts and Walnuts Using Artificial Neural Networks. *Food and Bioprocess Technology*, 8(5),
493 1113–1125.
- 494 Aune, D., Keum, N. N., Giovannucci, E., Fadnes, L. T., Boffetta, P., Greenwood, D. C., Tonstad,
495 S., Vatten, L. J., Riboli, E., & Norat, T. (2016). Nut consumption and risk of cardiovascular dis-
496 ease, total cancer, all-cause and cause-specific mortality: a systematic review and dose-response
497 meta-analysis of prospective studies. *BMC Medicine*, 14(1), 207.
- 498 Bolling, B. W., McKay, D. L., & Blumberg, J. B. (2010). The phytochemical composition and
499 antioxidant actions of tree nuts. *Asia Pacific Journal of Clinical Nutrition*, 19(1), 117–123.